

RESUMEN DE PROYECTO

L.A.I.S.S.

Los Angeles Intelligence & Safety System — análisis end-to-end de criminalidad LAPD 2020–2024, con modelos predictivos y dashboard de acceso abierto.

REPOSITORIO

LAPD-DATA-CRIME

PERÍODO

Ene 2020 – Dic 2024

REGISTROS

1,004,894 incidentes

GEOGRAFÍA

Ciudad de Los Ángeles — 21 divisiones LAPD

lapd-data-crime.vercel.app

De qué se trata

Análisis end-to-end de **1,004,894 incidentes** reportados al LAPD entre 2020 y 2024 (fuente: data.lacity.org, estándar FBI Uniform Crime Reporting), empaquetado como dashboard web interactivo de acceso abierto. No es solo exploración de datos: construye modelos predictivos honestos — hotspots, clearance (resolución de casos), forecast — y los expone en producción junto con un storytelling de datos en 12 capítulos.

17

CAPAS DE MAPA
(OSIRIS)

12

CAPÍTULOS DE
INSIGHTS

8

MODELOS ML

~3.450

LÍNEAS DE CÓDIGO ML

Metodología

Pipeline de datos

Limpieza → enriquecimiento con fuentes externas → export a JSON/GeoJSON estático que consume el frontend directamente (sin base de datos en el hot path del dashboard, salvo Supabase para el login demo).

Fuentes de enriquecimiento (julio 2026)

Todas unidas por nombre o GEOID, sin geocoding difuso:

FUENTE	APORTA
MyLA311	Proxy de desorden urbano (basura, grafiti, encampments, luminarias reportadas)
Bureau of Street Lighting	222k puntos de iluminación citywide (vía ArcGIS directo — el mirror Socrata devuelve vacío)
California ABC	23k licencias de alcohol activas por tracto censal
ACS Housing Tenure	Tasa de ocupación por propietario (vía mirror Esri — la API de Census no es alcanzable desde el entorno)
LA Zoning	58.9k parcelas, mix de uso de suelo por división LAPD

Disciplina anti-leakage

Es el rasgo más destacable del proyecto. Varios modelos comparten un `RELIABLE_CUTOFF` (2024-03-31), documentado explícitamente en el código de cada uno.

POR QUÉ

El "clearance rate" (tasa de resolución de casos) cae a ~2.5% en diciembre 2024 — no porque la policía dejó de resolver casos, sino porque un caso reciente no tuvo tiempo de madurar antes del snapshot de datos. Entrenar un modelo sobre esos meses le enseñaría "reciente = no resuelto" como patrón falso, en vez de una señal real. Por eso `ml_clearance.py`, `ml_hotspot_predict.py` y `ml_forecast.py` cortan el set de entrenamiento antes de esa fecha.

Validación honesta, no vanity metrics

El modelo predictivo de hotspots (capítulo 11 de Insights) se compara contra un baseline de persistencia simple — "¿qué tan seguido pasa crimen ahí, históricamente?" — y el propio dashboard admite cuando el modelo **no** supera al baseline ("statistically tied"). Al partir el análisis por franja horaria y tipo de día, el hit-rate mejoró más que agregar el modelo XGBoost por sí solo, y el dashboard lo comunica sin maquillarlo: "el modelo agrega solo +X% sobre la partición por horario". Es un proyecto que prioriza la verdad estadística sobre vender el modelo.

8 modelos ML (`src/ml_*.py`)

Clasificador de crimen

Clearance prediction (XGBoost + SHAP)

Forecast de series temporales (Prophet/statsmodels)

Hotspot KDE descriptivo

Hotspot predictivo (Predictive Accuracy Index)

Hotspot temporal (franja/tipo de día)

Hotspot por tipo de crimen

Hotspot por barrio

Proximidad a transporte

Tecnología

CAPA	STACK
Data prep	Python · pandas 3 · geopandas · shapely
ML	scikit-learn · xgboost · prophet · statsmodels · shap (explicabilidad)
Viz offline	matplotlib · seaborn
Dashboard	Next.js 16 · React 19 · Tailwind · Recharts · Google Maps API
Auth	Supabase (@supabase/ssr) — login demo, no gatea el acceso
Deploy	Vercel
Formatos	Parquet · GeoJSON · JSON
BI alternativo	Power BI, star schema exportado a CSV

Prácticas de ingeniería

- **CI en GitHub Actions** (`dashboard-ci.yml`): lint → build → smoke tests con Playwright sobre las 7 rutas principales, verificando ausencia de errores de consola. Corre solo cuando cambia `dashboard/**`.
- **Notebooks numerados** (`01_data_preparation` → `06_ml_classifier`) que importan de `src/` — separación clara entre exploración y lógica reusable.
- **Scripts standalone** en `scripts/` que escriben directo a `public/data/`, desacoplados del pipeline de notebooks.
- Historial de commits organizado por fase (Phase 5A → 5I), legible y trazable.

Producto — módulos del dashboard

RUTA	MÓDULO
/login	Landing + auth Supabase (acceso demo como invitado)
/dashboard	Analítica principal — KPIs, filtros tácticos (año/mes/turno/tipo de día/robo), capítulo de Arrestos
/osiris	Inteligencia geoespacial — 17 capas de mapa intercambiables: basemaps OSINT (heat, clusters, choropleth, mobility, edu-safety, jurisdicciones, densidad), capas LAPD (divisiones, calor LAPD, por 1.000 hab., vulnerabilidad, barrios, negocios), 3 capas ML de hotspot (riesgo, temporal, por barrio) y un overlay táctico estilo CIA
/insights	Storytelling de datos en 12 capítulos: 01 Escala del problema · 02 Crisis de resolución · 03 Geografía del crimen · 04 Qué crímenes se cometen · 05 Cuando golpea el crimen · 06 Quién carga el peso · 07 Índice de riesgo por barrio · 08 Quién es arrestado · 09 Forecast de crimen · 10 Predicción de resolución · 11 Predicción de hotspots · 12 Hallazgos clave
/geo	Vistas por distrito de consejo / jurisdicción
/compare	Comparación lado a lado
/glossary	Diccionario de datos / referencia metodológica (EN)
/twin	Módulo 3D City Twin

LIVE

lapd-data-crime.vercel.app — repositorio: github.com/licgermancardenas-crypto/LAPD-DATA-CRIME